


DETECCIÓN Y CLASIFICACIÓN DE TUMORES CEREBRALES UTILIZANDO UNA RED NEURONAL CONVOLUCIONAL

DIPLOMADO EN CIENCIA DE DATOS – DGTIC UNAM

PROYECTO FINAL – ENERO 2022

AUTOR: CRISTIAN ARMANDO, FLORES ÁLVAREZ



RESUMEN


El presente proyecto tiene como objetivo detectar y clasificar diferentes tipos de tumores cerebrales en Imágenes por Resonancia Magnética (MRI¹) mediante el uso de Redes Neuronales Convolucionales (CNN²).

A lo largo del documento veremos los siguientes puntos:

- **INTRODUCCIÓN Y CONTEXTO:** ¿Qué es un tumor cerebral?, tipos de tumores cerebrales y la importancia del tema.
- **DEFINICIÓN DEL PROBLEMA:** ¿Qué se pretende resolver?
- **DATOS Y DESCRIPTIVOS:** ¿Qué datos usaremos?, preprocesamiento y algunos descriptivos.
- **MÉTRICAS DE EVALUACIÓN Y DESCRIPCIÓN DE LA CNN:** Configuración de la red, Categorical Cross Entropy, Accuracy, ...
- **ENTRENAMIENTO DEL MODELO Y RESULTADOS:** Evaluación del performance de la red ...
- **CONCLUSIONES**

INTRODUCCIÓN


Partes del cerebro humano:



CONTEXTO

¿Qué es un tumor cerebral?

- Un tumor cerebral es una masa o bulto de células anormales que se encuentra en el cerebro.
- Existen varios tipos de tumores cerebrales:
 - Benignos: No cancerosos
 - Malignos: Cancerosos
- Se pueden originar en:
 - El cerebro (tumores cerebrales primarios)
 - En otras partes del cuerpo y se extiende hasta el cerebro (tumores cerebrales secundarios o metastásicos)



CONTEXTO (GLIOMA)

La CNN que entrenaremos será capaz de identificar y clasificar 3 diferentes tipos de tumores:

¿Qué es un glioma?


En el cerebro existen células **gliales** que brindan apoyo y protección para las neuronas.

El crecimiento anormal de estas células puede dar lugar a la formación de tumores en el **cerebro** o en **la médula espinal**, que se denominan gliomas.

Síntomas



Imágenes por Resonancia Magnética (Gliomas)




CONTEXTO (MENINGIOMA)


La CNN que entrenaremos será capaz de identificar y clasificar 3 diferentes tipos de tumores:

¿Qué es un meningioma?

Un **meningioma** es un tumor benigno que surge en las membranas que rodean el cerebro y la médula espinal.



Imágenes por Resonancia Magnética (Meningioma)




CONTEXTO (TUMOR PITUITARIO)


La CNN que entrenaremos será capaz de identificar y clasificar 3 diferentes tipos de tumores:

¿Qué es un tumor pituitario?

Los **tumores pituitarios** son crecimientos anormales que se desarrollan en la glándula pituitaria, también llamados adenomas.



Imágenes por Resonancia Magnética (Adenoma Pituitario)



DEFINICIÓN DEL PROBLEMA

- Al año, se diagnostican **300 mil nuevos** casos de tumores cerebrales en el mundo
- En México, el número de casos ocurridos es de 3.5 por cada 100 mil habitantes
- Según la OMS*, el diagnóstico adecuado de un tumor cerebral implica la **detección**, la identificación de la **ubicación** y la **clasificación** del tumor en función de la malignidad, el grado y el tipo.

LA IMPORTANCIA DEL TEMA

- La detección temprana y la clasificación de los tumores cerebrales es un dominio de investigación importante en el campo de las imágenes médicas y, en consecuencia, ayuda a seleccionar el método de tratamiento más conveniente para salvar la vida de los pacientes.

A continuación haremos uso de un conjunto de **MRI** para entrenar una **CNN**, la cual será capaz de detectar la existencia o no de un tumor cerebral, así como de clasificarlo con base en la ubicación del mismo.

CONJUNTO DE DATOS

El conjunto de datos utilizado para este proyecto es público y se puede encontrar en la siguiente liga de **Kaggle**: <https://www.kaggle.com/masoudnickparvar/brain-tumor-mri-dataset>, contiene 7,023 Imágenes por Resonancia Magnética (MRI) reales del cerebro humano, las cuales están clasificadas en 4 clases: **glioma**, **meningioma**, **pituitary** y **no tumor**.

- Número de clases: 4
- # Imágenes en conjunto de entrenamiento: 5,712
- # Imágenes en conjunto de prueba: 1,311

PREPROCESAMIENTO DE DATOS

El conjunto de imágenes originales tienen un **tamaño** y **color** variable, por lo que aplicaremos una serie de funciones que nos permitirán homologar ambos aspectos, además de quitar cierto ruido como marcos y centrar las imágenes.

Al final, todas las imágenes quedarán en escala de grises y de tamaño: **256x256** pixeles.



Las funciones con las que fueron pre-procesadas las imágenes pueden ser consultadas en el siguiente github:

<https://github.com/masoudnick/Brain-Tumor-MRI-Classification/blob/main/Preprocessing.py>


PREPROCESAMIENTO DE DATOS

Cada imagen fue procesada para que tuviera el mismo tamaño (256x256), color (escala de grises) y se quitó cierto ruido como marcos, además de centrar cada imagen:

Original




Procesada



SPLIT DE DATOS Y DESCRIPTIVOS


Previo al entrenamiento de la CNN, separamos aleatoriamente los datos de entrenamiento 80-20 para generar los datos de validación:

Entrenamiento (80%)



4,569 MRIs y 4 categorías


Validación (20%)



1,143 MRIs y 4 categorías

DATOS DE PRUEBA Y FORMATO TF-RECORDS

Datos de Prueba



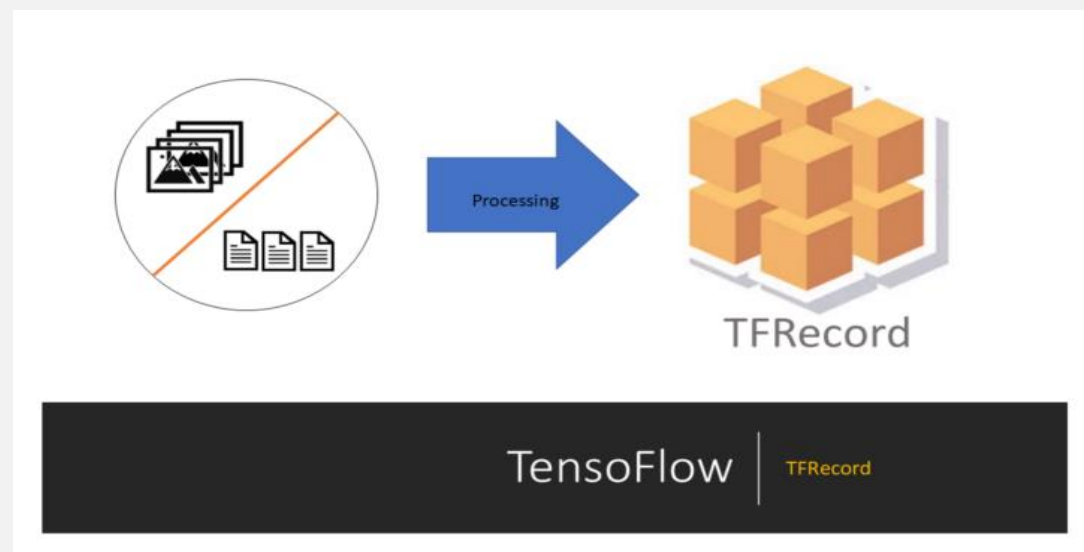
1,311 MRIs y 4 categorías

¿Qué es TFRecord?

TFRecord es un formato simple para almacenar una secuencia de registros binarios.

Por lo que las imágenes son convertidas en matrices o tensores de diferentes dimensiones y las etiquetas a listas de cadenas.

Uno de los beneficios de usar el formato TFRecord es el rendimiento durante el entrenamiento.



DEFINICIÓN DE MÉTRICAS DE EVALUACIÓN

Categorical Crossentropy:

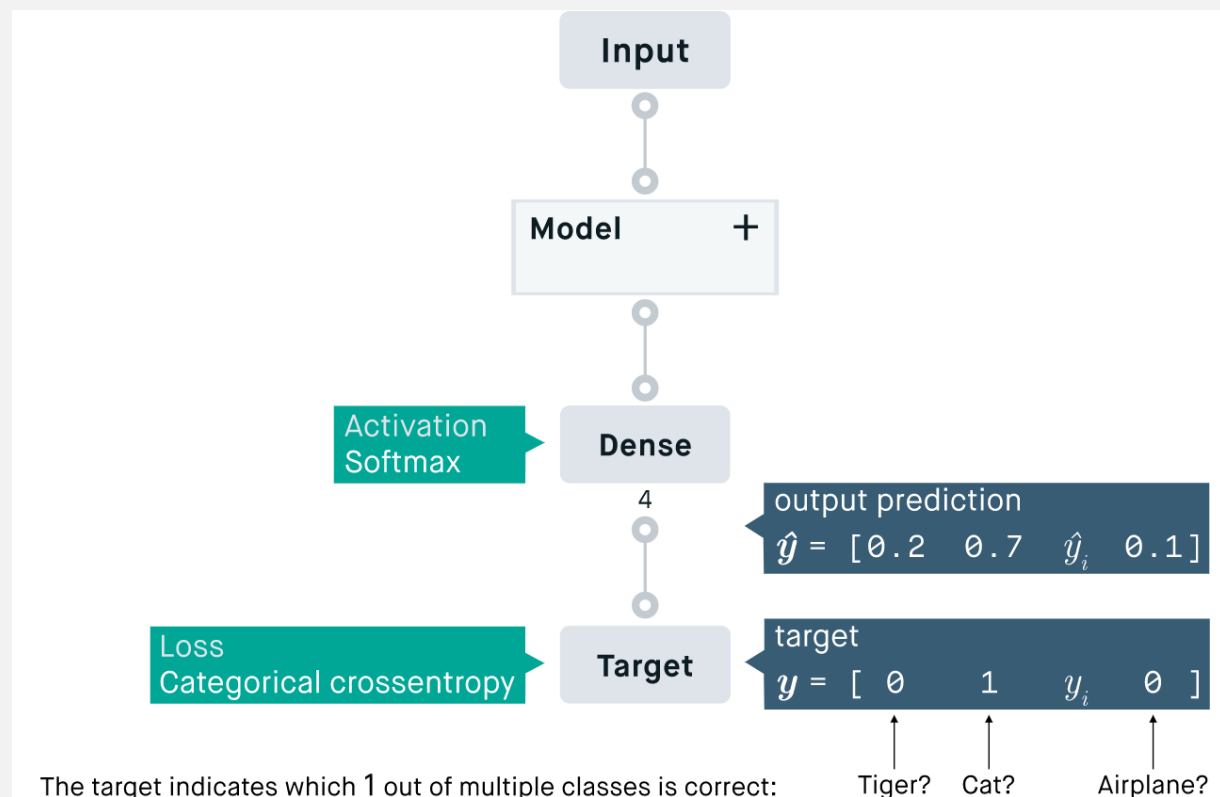
La entropía cruzada categórica es una función de pérdida que es usada para tareas de clasificación multiclase, donde un ejemplo puede pertenecer solo a **una sola** de muchas categorías posibles. Formalmente, está diseñada para cuantificar la diferencia entre dos distribuciones de probabilidad.

La pérdida de un ejemplo se calcula con la siguiente suma:

$$Loss = - \sum_{k=1}^K y_k \cdot \log(\hat{y}_k)$$

Donde, \hat{y}_k es el k-ésimo valor de la salida del modelo, y_k su correspondiente valor de target y K el número total de categorías.

Ejemplo: Categorical Crossentropy



DEFINICIÓN DE MÉTRICAS DE EVALUACIÓN

Categorical Accuracy:

La precisión categórica se calcula como el porcentaje de valores correctamente predichos entre el total de valores.

$$\text{Categorical Accuracy} = \frac{\text{Predicciones correctas}}{\text{Observaciones totales}} \times 100 \%$$

REDES NEURONALES CONVOLUCIONALES (CNN)

¿Cómo trabajan las CNN?





En términos muy generales, la configuración de una CNN puede agruparse en las siguientes secciones:

- Ingresa imagen
- Capas iniciales:
 1. Capa de convolución (Extracción de características)
 2. Capa de agrupación (Max Pooling)
- Agrupamiento Medio Global (Global Average Pooling)
- Red Neuronal Densa (Softmax layer)

REDES NEURONALES CONVOLUCIONALES (CNN)

Capa de convolución

La capa de convolución consiste en **extraer características** de las imágenes mediante **filtros** (kernel/feature detectors) que se **desplazan** a lo largo de los píxeles de la imagen para generar **mapas de características o activación**.



REDES NEURONALES CONVOLUCIONALES (CNN)

Capa de agrupación / submuestreo (Max Pooling)

La capa de agrupación o submuestreo permite eliminar información o características innecesarias de los **mapas de activación** creados en la capa de convolución.

En particular, **Max Pooling** le permite a la CNN detectar objetos de una imagen sin que sea confundida por rotaciones, distancias, ángulos, etc. A esta propiedad se le conoce como **"variación espacial"**

0	1	0	0	0
0	1	1	1	0
1	0	1	2	1
1	4	2	1	0
0	0	1	2	1

Feature Map

Max Pooling

1	1	0
4		

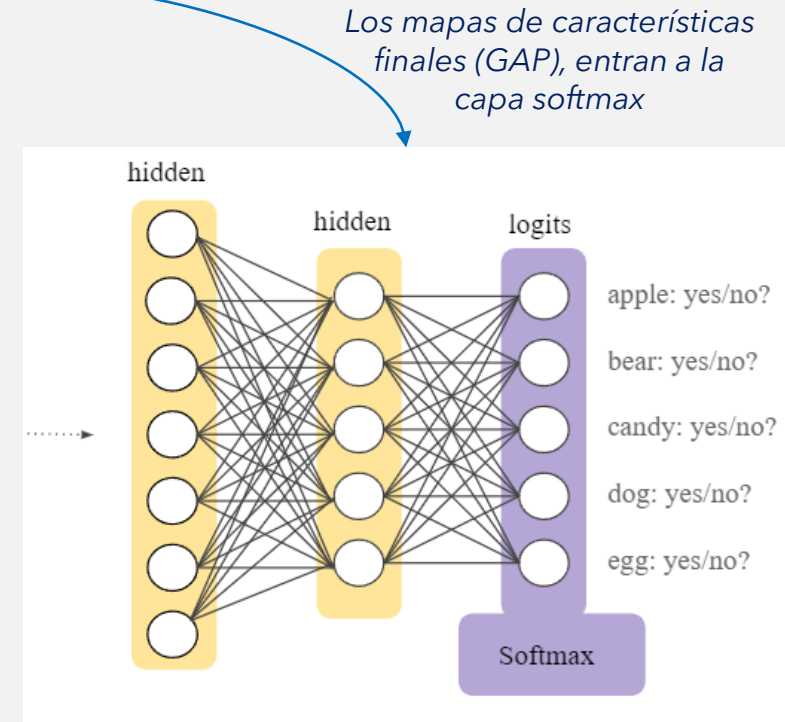
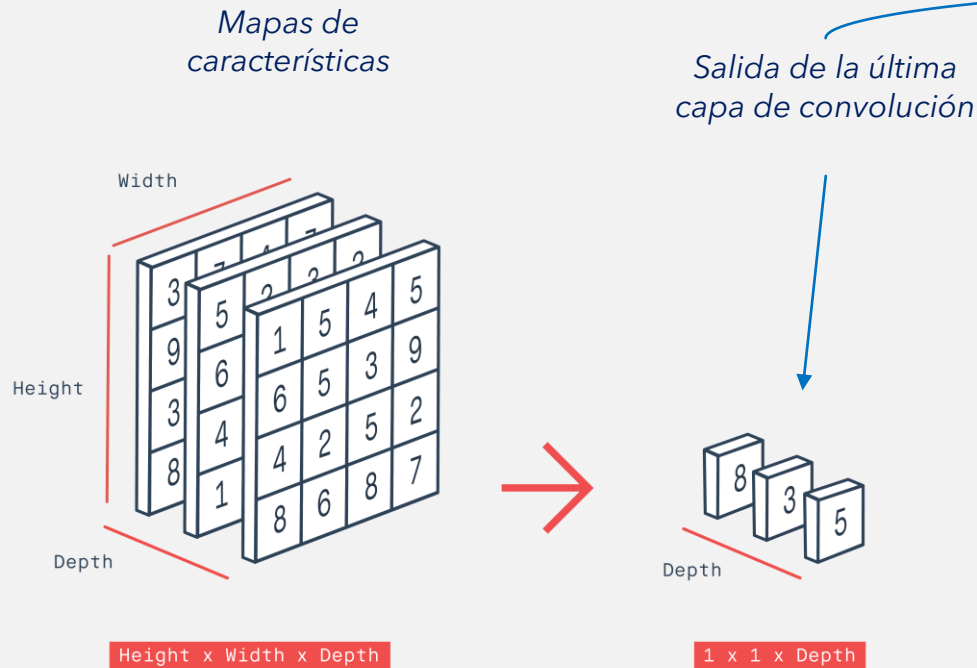
Pooled Feature Map



REDES NEURONALES CONVOLUCIONALES (CNN)

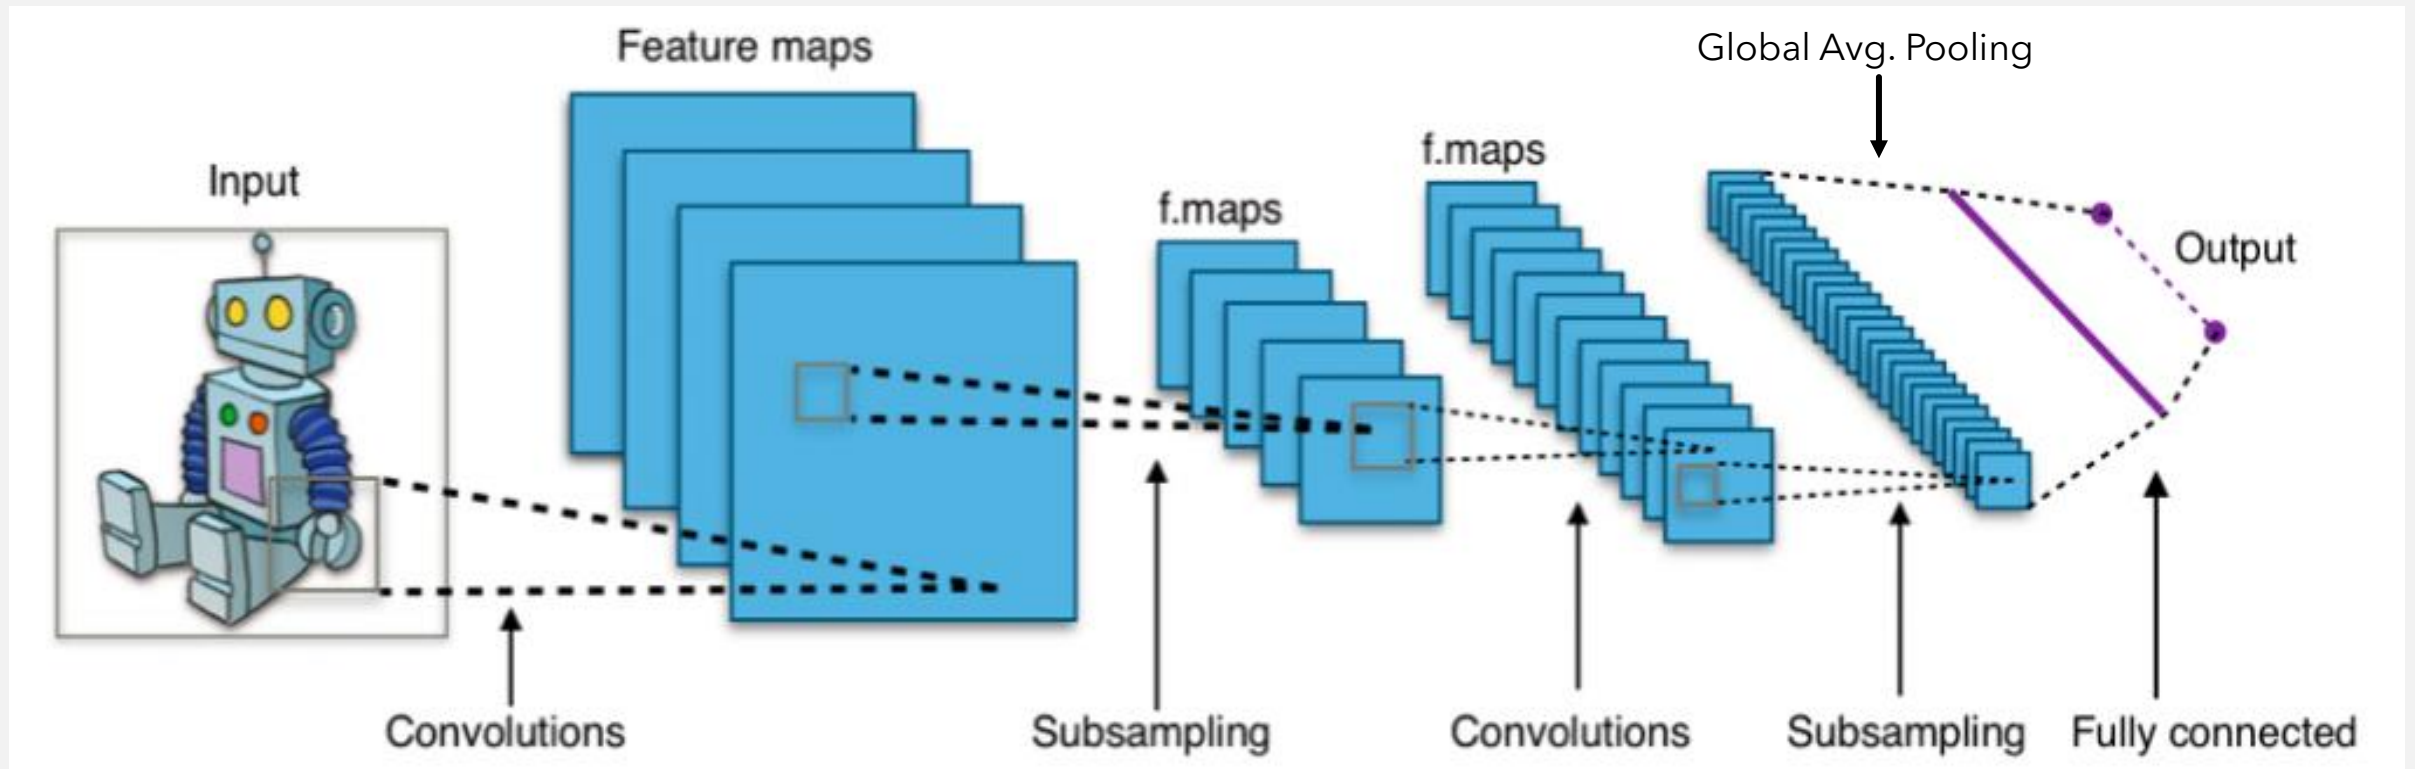
Global Average Pooling | Capa softmax

El **GAP** es una operación de agrupación que permite generar un mapa de características específico para cada categoría en un problema de clasificación multiclase, el vector resultante se introduce directamente en la capa softmax.



REDES NEURONALES CONVOLUCIONALES (CNN)


Al final, el proceso completo se ve de la siguiente manera:



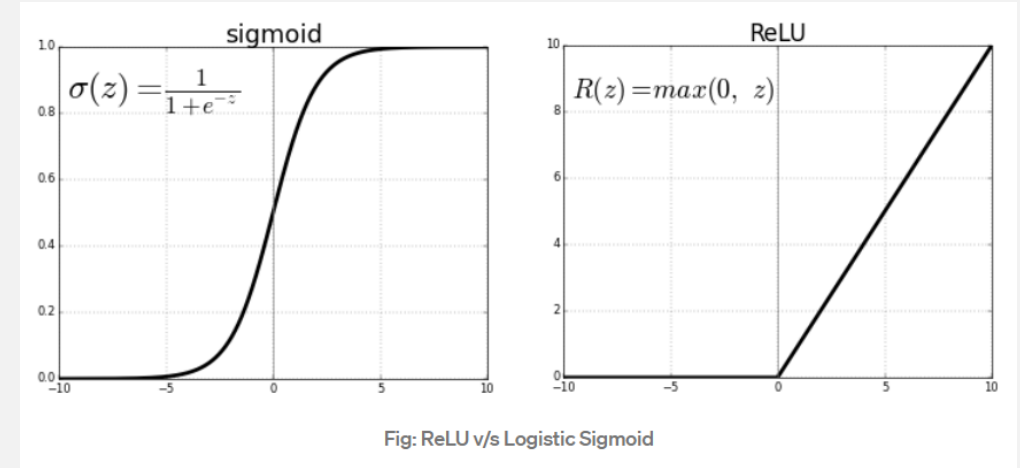
FUNCIONES DE ACTIVACIÓN:

¿Qué es una función de activación?

Es básicamente una función **no lineal** que se aplica a la **suma ponderada** de cada neurona para obtener una **salida** de la misma:



De momento nos importan 2, ..., bueno 3



Sigmoide: Esta función mapea cualquier valor real a valores entre 0 y 1, por lo que es altamente usada en modelos de predicción donde nos interesa predecir una probabilidad.

Softmax: Generalización de la función sigmoide que es usada para clasificación multiclase.

ReLu: Esta función es la más usada para CNN, lo que hace es enviar a 0 a todos los valores negativos.

ENTRENAMIENTO DEL MODELO

Conjunto de datos:

Como lo vimos en la sección de datos, el conjunto de entrenamiento lo dividimos aleatoriamente **80/20** para contar con un conjunto de validación (**4.6K / 1.1K** MRIs respectivamente):


Software:

La CNN fue entrenada usando TensorFlow y Keras (2.7.0), con Python3



Aumento de datos:

Antes de comenzar con las iteraciones del entrenamiento, se realizó un aumento de datos mediante rotaciones, acercamientos y volteos de imagen.



CONFIGURACIÓN DE LA CNN

La CNN está se entrenó con la siguiente configuración durante **30** épocas / iteraciones:

- **Capas de entrada / iniciales:**

- Capa convolucional: 256 filtros de 7 x 7 y desplazamiento de 2 y función de activación **ReLU**.
- Max pooling: Tamaño 3 x 3 y desplazamiento de 2.

- **Capas intermedias /ocultas:**

- Capa convolucional 1 (Entradas: 256, salidas: 256, función de activación ReLU)
- Capa convolucional 2 (Entradas: 256, salidas: 512, función de activación ReLU)
- Capa convolucional 3 (Entradas: 512, salidas: 256, función de activación ReLU)
- Capa convolucional 4 (Entradas: 256, salidas: 128, función de activación ReLU)

- **Global Average Pooling:** (Entradas: 128, salidas: 4)


- **Red Neuronal Densa: 4 clases** y función de activación **softmax**

Con esta configuración el número de parámetros a entrenar
asciende a: **15 MM**


EVALUACIÓN DE LA CNN

Aprendizaje de la CNN durante las 30 épocas

Learning Curve: ECC



Learning Curve: Accuracy



Observe que el performance del modelo va mejorando conforme avanzan las épocas, al final nos quedamos con aquel modelo con la menor ECC en el conjunto de validación (en este caso fue el modelo de la iteración **29**).

RESULTADOS

Performance del modelo final:



Sample	ECC	Accuracy
Entrenamiento	0.43	84.1%
Validación	0.34	89.4%
Prueba	0.51	81.1%

Notemos que la variación % de la precisión entre los datos de entrenamiento y prueba es del **3.6%**, mientras que la ECC sube de 0.43 a 0.51, este performance podría ser mejorado con un mayor número de épocas.

En la imagen de la derecha se muestran las predicciones realizadas por la CNN sobre 25 imágenes aleatorias del conjunto de prueba.

Azul: Predicción correcta

R rojo: Predicción errónea



CONCLUSIONES

Como pudimos observar a lo largo del documento, las Redes Neuronales Convolucionales son una herramienta útil que pueden ayudar a detectar con un alto grado de certeza diferentes tipos de **cáncer cerebral**, esto es importante ya que, como vimos anteriormente, la **detección temprana** y la **clasificación** de los tumores cerebrales ayuda a seleccionar el método de tratamiento más conveniente para salvar la vida de los pacientes.

Una herramienta como esta, que pueda estar al alcance de hospitales o centros de salud a través de una aplicación amigable con los usuarios, podría eficientar los diagnósticos de muchos pacientes y por ende vidas.

Con respecto al modelo, este es perfectible, con un mayor poder de cómputo, mayores ejemplos de entrenamiento y explorando diferentes configuraciones de la CNN, se podría alcanzar mejores métricas en los datos de prueba.

REFERENCIAS

- [DGTIC-UNAM: Diplomado en Ciencia de Datos \(Módulo 8: Introducción al Deep Learning, Dr. Gibrán Fuentes\)](#)
- [https://frogames.es/la-guia-definitiva-de-las-redes-neuronales-convolucionales/](#)
- [https://peltarion.com/knowledge-center/documentation/modeling-view/build-an-ai-model/loss-functions/categorical-crossentropy](#)
- [https://www.youtube.com/watch?v=4sWhhQwHqug](#)
- [https://towardsdatascience.com/keras-accuracy-metrics](#)
- [https://blog.gammaknifedelpacifico.com/glioma-causas-sintomas-y-opciones-de-tratamiento](#)
- [https://blog.gammaknifedelpacifico.com/meningioma-causas-sintomas-y-opciones-de-tratamiento](#)
- [https://blog.gammaknifedelpacifico.com/cuales-son-los-tipos-de-adenomas-pituitarios](#)
- [https://www.dgcs.unam.mx/boletin/bdboletin/2020_580.html](#)
- [https://www.kenhub.com/es/library/anatomia-es/cerebro-es](#)
- [https://towardsdatascience.com/activation-functions-neural-networks-1cbd9f8d91d6](#)

GRACIAS POR SU ATENCIÓN

DIPLOMADO EN CIENCIA DE DATOS – DGTIC UNAM

PROYECTO FINAL – ENERO 2022

PREGUNTAS | FEEDBACK



DIPLOMADO EN CIENCIA DE DATOS – DGTIC UNAM

PROYECTO FINAL – ENERO 2022
